EmbeddingGemma 2 실습 최종 보고서 (보드 B, 1~10단계)

Oct 28, 2026

한눈에 보기

보드 B(team5-b)에서 README 1~10단계 가운데 7단계를 뺀 9개 단계를 모두 끝냈다. 7단계는 저장소의 학습 데이터(train/eval.jsonl)가 없어 미뤘다.

- 팀: 4명이 2명씩 나눠 진행. 지영 팀은 보드 B, 다른 팀은 보드 A에서 1~9단계를 따로 했다.
- 10단계는 USB 카메라 2대를 보드 B로 모아 지영 팀이 먼저 했고, 보드 A 팀이 다음에 한다.
- 보드: Jetson Orin Nano 8GB, L4T R39(JetPack 7 계열), Python 3.12, SSD 부팅, MAXN_SUPER(전원 모드 2), 스왑 8GB
- 접속: `ssh jiyeong@team5-b` (Tailscale 100.126.215.96), 가상환경 `~/eg2`, 작업 폴더 `~/eg2-lab`

단계	내용	상태	핵심 결과
1~3	환경 설정, 모델 받기, 텍스트 검색	완료	768/256/128차원 모두 정답 1위, 약 150~160ms
4	이미지·동영상 검색	완료	이미지 5장 2.7초, 10초 영상 2.0초
5	음성 검색	완료	실제 목소리 녹음으로 3개 질의 모두 정답
6	성능 측정	완료	텍스트 전용 RAM +1.4GB, 비전 +2.2GB
7	미세조정	미진행	학습 데이터 파일 필요
8	YOLO 웹캠 앱	완료	yolo 15fps, relabel 15~17fps, yoloe 13fps
9	포즈 동작·행동	완료	동작 4종 실시간 인식, 행동 4장면 모두 맞음
10	두 카메라 근접 알람	완료	알람 시나리오 5개 모두 3/3, 이동 타겟 충돌 알람 동작

1~3단계 환경 설정

두 보드 모두 같은 환경을 만들었고, 텍스트 검색은 모든 차원에서 정답을 1위로 찾았다.

- torch 2.14.1+cu132, torchvision 0.29.1+cu132 (버전은 `~/eg2/torch-pin.txt`로 고정)
- sentence-transformers 6.2.0, transformers 5.20.2, 모델 google/embeddinggemma-2 (bfloat16)
- 스왑 8GB(`/swapfile`), 전원 모드 MAXN_SUPER는 이 보드에서 `nvpmodel -m 2` (README의 `-m 0`은 15W)
- torchaudio는 README Q7 충돌 때문에 설치하지 않음

차원	지연 (ms)	"졸리고 머리가 맑지 않아요"	"여름 냉방 몇 도?"
768	160	CO2 환기 문장 (0.717)	에어컨 온도 문장 (0.725)
256	151	CO2 환기 문장 (0.734)	에어컨 온도 문장 (0.754)
128	162	CO2 환기 문장 (0.785)	에어컨 온도 문장 (0.810)

차원마다 점수 기준이 달라서 점수끼리 직접 비교하지는 않는다.

4~6단계 이미지·영상·소리 검색과 측정

이미지·동영상·음성 검색이 모두 동작했고, 음성은 합성음 대신 실제 목소리를 넣어야 정답을 찾았다.

4단계 이미지·동영상: C920 웹캠으로 10초 영상(clip.mp4)과 2초마다 프레임 5장을 찍었다. "모니터 화면" 질의는 frame_04(0.706)를 찾았고, 나머지 질의는 같은 공간이라 0.59~0.66으로 비슷했다. 질의-동영상 유사도는 0.635~0.698이다.

5단계 음성

질의	합성음만 있을 때	실제 목소리(mic.wav) 추가 후
덥다고 냉방을 요청하는 목소리	noise.wav (0.651) ✗	mic.wav (0.713) ✓
날카로운 경보음	beep.wav (0.702) ✓	beep.wav (0.702) ✓
웅웅거리는 배경 소음	noise.wav (0.682) ✓	noise.wav (0.682) ✓

6단계 성능 (RAM은 tegrastats 최대값, 괄호는 실행 전 약 2.9GB 대비 증가량)

구성	로드 크기	로드 후 RAM (MB)	입력	지연 (ms)	GPU 사용률 (%)
텍스트 전용	270M	4272 (+1397)	질의 2개	약 150~160	24
+비전	440M	5126 (+2164)	이미지 5장	2739	100
+비전	440M	5126 (+2164)	동영상 10초	1960	100
+오디오	570M	4919 (+2032)	WAV 4개	1229	84

전체(740M) 구성은 측정하지 않았다.

8~9단계 YOLO 웹캠 앱과 포즈 동작·행동

YOLOE는 COCO에 없는 물체도 이름으로 찾았고, 포즈 앱은 동작 4종과 행동 4장면을 모두 실시간으로 알아봤다.

8단계 세 방식 비교 (검출 속도: yolo 15fps, relabel 15~17fps, yoloe 13fps)

물체	yolo	relabel	yoloe
무선 이어폰	remote / mouse ✗	무선 이어폰 ✓	mouse ✗
드럼 세탁기	microwave ✗	드럼 세탁기 ✓	drum washing machine ✓
선풍기	clock ✗	천장 에어컨 ✗ (목록 추가 전)	electric fan ✓
시계	clock ✓	휴대폰 ✗ (목록 추가 전)	wall clock ✓
천장 에어컨	microwave ✗	미확인	ceiling air conditioner / microwave △
모자	suitcase ✗	컵 ✗ (목록 추가 전)	umbrella ✗

relabel은 `LABELS` 목록에 있는 물체만 바로잡고, 목록 밖 물체는 엉뚱한 이름으로 바꾼다. 강의실에서는 YOLOE로 후보를 찾고 임베딩으로 한 번 더 확인하는 조합이 가장 낫고, 10단계 타겟 찾기가 바로 이 방식이다.

9단계 포즈 (yolo11n-pose, 관절 17개)

- 9-1 한 프레임 판정: 만세·한팔들기·악수는 됨, 손 흔들기는 안 됨 (README 예상과 같음)
- 9-2 시간 정보 사용: 손 흔들기도 인식. 단, 팔을 머리 옆까지 들고 크고 빠르게 흔들어야 함
- 9-5 행동 규칙: 지나감·힐끗 봄·관심 있음·머무름 4장면 모두 3회씩 맞음
- 9-6 동작 모델(GRU, window 30): 검증 정확도 0.989. 실시간에서는 특징 표준편차 최소값을 1e-6에서 0.03으로 바꾸고 박수를 30초 더 녹화하자 idle·wave·clap·arms_crossed 모두 인식
- 9-6 행동 모델: 한 번 지나가는 데 1.5~2초라 README의 `--window 80`으로는 학습 데이터가 0개였다. `--window 15`로 학습해 검증 0.364였지만, 실시간에서는 4장면이 모두 맞았다

동작 모델의 검증 점수는 같은 녹화의 뒷부분으로 잔 것이라, 실제 성능은 이보다 낮다.

10단계 두 카메라 근접 알람

두 카메라 방식(stereo·fused)은 서 있는 사람 거리를 0.15m 안팎으로 맞혔고, 알람 시나리오 5개는 모두 3/3 성공했다. 자세한 내용은 10단계 보고서에 따로 정리했다.

- 카메라: C920 2대, cam0 = `/dev/video0`, cam1 = `/dev/video2` (`--cams 0 2`), 자동초점 끔
- 10-1 렌즈 보정: cam0 RMS 0.372px, cam1 0.355px
- 10-2 위치 보정(3차 최종): cam0 3.78px, cam1 3.22px, 검증점 오차 3cm. 카메라 간격 1.14m

실제 거리·자세	ankle1	stereo	fused
0.5m 서 있음	0.56	0.61	0.63
1.0m 서 있음	1.18	1.06	1.21
2.0m 서 있음	2.05	2.14	2.11
3.0m 서 있음 (꺼진 바닥)	2.77	3.05	3.15
0.81m 책상에 앉음	1.45 (ID 끊김)	0.67	0.91
한 카메라에만 보임 (1.81m)	-	사라짐	0.55
fps	26.7	23.1	23

- 10-6 알람: 갈색 상자를 "brown cardboard box"로 찾아 두 카메라 삼각측량. 다가옴·나감·경계에 서 있기·옆으로 지나감·앉기 모두 3/3
- 10-8 이동 타겟: 사람이 상자를 낮게 들고 걸어옴. 충돌 위험 알람은 근접 알람보다 천천히 3초, 보통 약 1초, 빠르게 몇 프레임 먼저 울림
- 한계: 카메라가 어깨 높이(1.35~1.41m)라 한 카메라 추정이 크게 튀고, 카메라 간격이 좁아 멀수록 앞뒤 오차가 커짐

겪은 문제와 해결

README대로 안 됐던 곳은 대부분 보드 환경(NVIDIA FFmpeg, 라이브러리 버전)과 카메라 배치 때문이었다. 보드 A 팀도 같은 문제를 만날 수 있다.

단계	문제	원인	해결
1	`nvpmodel -m 0`이 15W 모드	이 보드는 MAXN_SUPER가 2번	`sudo nvpmodel -m 2` 후 재부팅
4	ffmpeg로 웹캠 녹화 안 됨	NVIDIA FFmpeg에 v4l2 입력 없음	OpenCV로 녹화 (`record.py`)

단계	문제	원인	해결
4	동영상 임베딩 실패	torchcodec에 필요한 libswscale 없음	`sudo apt install libavcodec60 libavformat60 libavutil58 libswscale7 libswresample4 libavdevice60 libavfilter9` 후 `pip install -c ~/eg2/torch-pin.txt torchcodec`
5	경보음·잡음 생성 안 됨	FFmpeg에 lavfi 없음	numpy로 생성 (`gen_audio.py`)
5	목소리 질의가 잡음을 찾음	espeak 합성음이 사람 목소리 같지 않음	C920 마이크로 실제 녹음 (`arecord -D plughw:2,0 ...`)
8~10	프레임마다 경고	ultralytics 8.4.184에서 `half=True` 지원 종료	코드에서 `, half=True` 삭제
9	가만히 있어도 wave	녹화 때 얼굴이 화면 밖이라 얼굴 특징 표준편차가 0	표준편차 최소값 0.03 + 박수 30초 추가 녹화
9	행동 모델 학습 데이터 0개	한 번 지나가는 데 1.5~2초	`--window 15`
10-1	렌즈 보정 RMS가 들쓰날쓰	C920 자동초점	`v4l2-ctl -d /dev/videoN -c focus_automatic_continuous=0` , `-c focus_absolute=0` (다시 꼽으면 다시 실행)
10-2	보정을 3번 함	책상 위 작은 범위, 다음엔 공간이 좁아 3m 불가	방 전체에 기준점, 원점은 바닥, 카메라는 사람 전신이 보이게
10-2	위치 계산이 터짐 (172px)	실측 번호와 클릭 번호가 엇갈림 (3↔4번)	json에서 두 점 좌표 교환
10-6	작은 상자를 cam1이 못 찾음	박스가 16px보다 작으면 후보에서 빠짐	큰 갈색 상자로 바꿈
10-8	타겟이 10m 밖으로 튀	상자를 카메라 높이에 가깝게 들면 한 카메라 추정이 폭주	상자를 무릎~허리 높이로 들기
10-8	상자가 8m 밖, 바닥 아래로 잡힘	보정 뒤 cam0이 약 6° 돌아감	보정 때 화면 사진과 비교해 손으로 다시 맞춤 (0~2px)

보드에서 `sudo apt autoremove` 는 실행하지 말 것. initramfs-tools, linux-base까지 지우려 한다.

남은 일과 보드 A 팀 참고

보드 B 몫은 7단계만 남았고, 보드 A 팀은 10단계를 할 차례다.

- [ ] 7단계: 저장소의 train.jsonl / eval.jsonl을 받은 뒤 진행
- [ ] 보드 A 10단계: 10-1 렌즈 보정은 같은 카메라라면 보드 B 결과(`calib/cam0.npz`, `cam2.npz`)를 복사해 쓸 수 있음. 10-2는 카메라를 놓은 자리에서 반드시 새로 해야 함

보드 A에서 10단계 전에 미리 확인할 것:

1. 카메라를 다시 꼽을 때마다 자동초점 끄기 (10-1 명령)
2. 기준점은 방 전체에 퍼지게, 바닥과 높은 곳을 섞어서. 맨 바깥 기준점 + 0.5m 밖의 사람은 무시됨
3. 카메라는 가능하면 README 권장대로 2.2~2.5m 높이, 두 시선 각도 60~90°. 보드 B는 1.4m 높이, 23°라 한계가 보였음
4. 카메라 놓인 책상은 건드리지 않기. 보정 직후 두 카메라 화면을 스크린샷으로 남겨 두면 움직였는지 비교할 수 있음
5. 코드의 `, half=True` 삭제, 동영상용 FFmpeg 라이브러리 설치는 위 표 참고

결과 원본 파일: 프로젝트 파일의 `embedding_gemma2/` 폴더 (results_boardB.md, step8 / step9 / step10_results_boardB.md)